

California Housing - Task 1

Multiple Linear Regression in california Dataset

Submitted by: Shivam | Internship Task 1 | 30 Aug
2026

Objective and Dataset

- Objective: California Housing Dataset पर Multiregression मॉडल बनाकर House Price (घर की कीमत) की भविष्यवाणी करना .

- Total Rows (कुल पंक्तियाँ): 20,640
- Total Features (कुल विशेषताएँ): 8 (MedInc, HouseAge, AveRooms, AveBedrms, Population, AveOccup, Latitude, Longitude)
- Target Variable: Median House Value (मध्य घरेलू मूल्य)

Exploratory Data Analysis (EDA) & Insights

Missing Values: डेटासेट में कोई Missing (गुम) वैल्यू नहीं हैं।



सबसे ताकतवर Feature: MedInc (Income) का House Price पर सबसे ज्यादा असर है।
(Correlation = 0.69)



Multicollinearity: AveRooms और AveBedrms आपस में बहुत ज्यादा मिलते-जुलते हैं।
(Correlation = 0.85)

- Target Distribution: House Price (target) Right-Skewed (दाईं ओर झुका हुआ) है, मतलब सस्ते घर ज्यादा हैं, महँगे कम।

Model Building (Linear Regression)

- Algorithm (अल्गोरिदम): `LinearRegression` (Multiple Linear Regression)
- Libraries Used (इस्तेमाल की गई लाइब्रेरीज़): Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn
- Train-Test Split (डेटा का बँटवारा):
 - Training Data (सीखने के लिए): 80% (16,512 Rows)
 - Testing Data (परीक्षा के लिए): 20% (4,128 Rows)
- Model Training (मॉडल को सिखाना): `model.fit(X_train, y_train)` के माध्यम से Betas (Coefficients) निकाले गए।
- Prediction (भविष्यवाणी): Test Data (4,128 Rows) पर `model.predict(X_test)` चलाकर अनुमानित (Predicted) कीमतें निकाली गईं।

Model Evaluation on test Data

MAE(mean absolute error) = .535

RMSE(root mean square error) = .724

R² SCORE = 0.596

Conclusions and Finals visuals

- **ग्राफ (Visuals) क्या बताते हैं?**
 - **Actual vs Predicted Scatter:** हरे बिंदु (Dots) लाल Perfect Line के आसपास अच्छे से बिखरे हुए हैं। मतलब हमारी भविष्यवाणी असली कीमतों के काफी करीब है।
 - **Residuals (गलतियाँ):** Residuals का Distribution Bell Curve (घंटी) के आकार में 0 (शून्य) के आसपास केंद्रित है, जो बताता है कि मॉडल की गलतियाँ बेतरतीब (Random) हैं।
- **मॉडल की कमी (Limitation):**
 - बहुत महंगे घरों (Price > 4) पर हमारी भविष्यवाणी थोड़ी कम (Underestimate) आ रही है। (जैसा Residuals vs Predicted Graph में दिखा)।
- **भविष्य के सुधार (Next Steps):**
 - अधिक सटीकता (Accuracy) के लिए Polynomial Features या Ridge/Lasso Regression का इस्तेमाल किया जा सकता है।

[illegible]